

Segmentación automatizada de tumores cerebrales en niños

Implementación de un modelo 3D Unet

Introducción

Para este proyecto nos enfocaremos en el uso de las tecnologías para apoyar la medicina y más precisamente el uso de inteligencia artificial en los diagnósticos mediante imágenes.

A nivel global, el cáncer es una de las primeras causas de muerte en menores y cada año se diagnostican 400 000 nuevos casos en niños y adolescentes de 0 a 19 años (OMS). Si bien existen factores genéticos en algunos casos específicos, la mayoría son imprevisibles.

En España, se trata de la primera causa de muerte en niños y adolescentes y cada año se registran 1500 nuevos casos. A pesar de que la tasa de supervivencia es alta en los países de ingreso alto, al usar terapias agresivas las consecuencias sobre la salud a largo plazo pueden ser devastadoras.

La supervivencia de los pacientes depende directamente del acceso al diagnóstico y a los tratamientos, es decir que cuanto antes se detecte un cáncer y cuanto antes se trata, mayor será la probabilidad de sobrevivir. Sin embargo, hoy en día se está experimentando falta de recursos a nivel de la sanidad pública y a consecuencias retrasos en los diagnósticos.

En el caso de los tumores cerebrales, para poder tratar el cáncer mediante cirugía o radioterapia, previamente se tiene que delimitar el tumor por resonancia magnética. En efecto, a partir de la resonancia un médico experto tiene que evaluar cada capa del cerebro (rebanadas) manualmente para establecer los límites del tumor. Al tratarse de un volumen 3D de 155 capas esa tarea supone una cantidad de tiempo muy elevada para cada paciente además de la carga de estrés conjunta. En caso de error eso significa dañar tejido cerebral sano y por ende, comprometer la función cerebral asociada (hablar, caminar, ver... etc) así como la calidad de vida del paciente a futuro.

Al día de hoy, se han desarrollado muy pocos métodos de segmentación automatizada de tumores en niños cuando existe una especificidad tanto de los tumores en esa población como de la misma estructura de sus cerebros. A diferencia de los tumores cerebrales en adultos, se caracterizan por la presencia de quiste alrededor del tumor, es decir líquido atrapado en cavidades alrededor del tumor. Por lo tanto hay un reto para delimitar el tumor de esos quistes específico a la población pediátrica y es la razón por la cual los modelos desarrollados para adultos no resultan eficientes.

La base de datos

Para este proyecto, hemos usado la base de datos ***Brain Tumor Segmentation in Pediatrics (Brats-Ped)***, una base de datos diseñada específicamente para neurooncología pediátrica.

Incluye un total de 457 pacientes con diagnóstico confirmado de tumor cerebral (gliomas de alto grado, astrocitomas o gliomas difusos de líneas medias) procedente de Estados Unidos, ya que estos datos han sido proporcionados por instituciones de ese país.

La base de datos está estructurada de la siguiente manera:

- Training : 257 escaneos de resonancia magnética multiparamétrica (mpMRI) con máscaras de segmentación validadas por expertos.
- Validación: 91 escaneos de resonancia magnética multiparamétrica (mpMRI)
- Prueba / Test: Cohorte oculta de 109 escaneos, utilizada para la evaluación del rendimiento final.

Para cada paciente, las resonancias magnéticas multiparamétrica están divididas en 4 archivos uno por cada modalidad de resonancia:

- **T1:** Resonancia estructural básica (antes del contraste).
- **T1CE:** Resonancia con contraste (resalta las zonas con mayor flujo sanguíneo, clave para ver el tumor activo).
- **T2:** Resonancia sensible a los líquidos (ayuda a ver la anatomía general y fluidos).
- **T2-FLAIR:** Resonancia que apaga el líquido cefalorraquídeo normal para hacer resaltar el **edema** (la inflamación) y el tejido tumoral.

Al ser una base de datos proporcionada para un reto solo la parte de entrenamiento incluye dos carpetas, una con la resonancia magnética (dividida en 4 archivos como lo mencionamos antes) y una de segmentación, es decir una imagen con el tumor segmentado y coloreado. La máscara de segmentación se compone de 5 clases:

- 0: **Normal:** Tejido cerebral sano.
- 1: **Tumor con realce** (ET): Áreas que captan contraste en la secuencia T1c (se ven más brillantes en comparación con T1).

- 2: **Tumor sin realce** (NET): Tejido tumoral con señal anormal que no capta contraste, visible en T1, T2 o FLAIR.
- 3: **Componente quístico** (CC): Regiones tumorales llenas de líquido (hiperintensas en T2 e hipointensas en T1c, similares al líquido cefalorraquídeo).
- 4: **Edema peritumoral** (ED): Inflamación alrededor del tumor, caracterizada por una señal hiperintensa en secuencias FLAIR con aspecto ramificado que conserva la estructura cerebral.




Figura 1. Conjunto de datos multimodal (BraTS) y segmentación anatómica. Representación de las secuencias de Resonancia Magnética (T1c, T1n, T2f, T2w) y la máscara de referencia (*Ground Truth*) correspondiente.
(<https://www.sciencedirect.com/science/article/pii/S2772528624000013>)

Problemática

Existe una necesidad clínica de agilizar los procesos previos al tratamiento de un tumor cerebral en niños donde cada minuto cuenta. Un humano tarda horas en segmentar un tumor de forma manual, y existe una variabilidad entre expertos ya que dos radiólogos altamente cualificados pueden dibujar límites diferentes para el mismo tumor, lo que introduce un componente de subjetividad en una decisión donde la precisión milimétrica es vital para salvar tejido cerebral sano. De ahí la necesidad de usar modelos de automatización para delimitar esos tumores.

Metodología

Hemos abordado este problema trabajando desde Python con un modelo de redes neuronales, más precisamente la arquitectura **3D U-Net**, la cual ha sido adaptada para procesar volúmenes tridimensionales de resonancia magnética y clasificar simultáneamente cinco subregiones críticas del tejido cerebral.

Red Neuronal Convolutacional

Una Red Neuronal Convolutacional es un tipo de red neuronal especializada en el procesamiento de imágenes. Su funcionamiento se basa en la aplicación de **filtros matemáticos** que recorren la imagen de forma sistemática.

- **Proceso de convolución:** El modelo desliza filtros sobre los datos de entrada para detectar patrones espaciales específicos, como gradientes, bordes o texturas.
- **Jerarquía de capas:** A medida que la información avanza a través de las capas de la red, esta combina los patrones simples detectados inicialmente para identificar estructuras más complejas y abstractas.
- **Reducción de dimensionalidad:** Mediante operaciones de muestreo (*pooling*), la red reduce el tamaño de los datos manteniendo únicamente la información más relevante, lo que permite que el modelo se enfoque en las características distintivas del objeto a clasificar.

U-Net 3D

La U-Net 3D es una arquitectura de red neuronal diseñada para la **segmentación semántica**, es decir, para clasificar cada vóxel (píxel en 3D) de un volumen de datos como parte de una estructura específica (por ejemplo, tumor o tejido sano). Su nombre deriva de su estructura simétrica en **forma de "U"**:

- Ruta de contracción (**Encoder**): El modelo reduce la resolución espacial del volumen de entrada para extraer el contexto global. En esta fase, la red aprende qué elementos están presentes en la imagen y su relación espacial.

- Ruta de expansión (**Decoder**): La red reconstruye la resolución original del volumen capa por capa. Este proceso permite asignar una etiqueta de clase a cada posición espacial en el espacio tridimensional original.
- Conexiones de salto (**Skip Connections**): Es la característica fundamental de la U-Net. Estas conexiones trasladan la información detallada desde la ruta de contracción directamente a la ruta de expansión. Esto permite recuperar la precisión espacial que se pierde durante la reducción de resolución, facilitando que el modelo delimite los contornos con alta exactitud.

Esta combinación permite que el modelo procese volúmenes médicos completos y realice una segmentación volumétrica precisa en lugar de analizar cortes individuales de manera aislada.

Como consecuencia de la estructura de la base de datos orientada al reto, hemos tenido que reorganizarla con el fin de tener las imágenes originales y la segmentación del tumor realizada por expertos tanto en las fases de entrenamiento como de validación y test

Para ello, se aplicó una estrategia de división estricta (Split) a nivel de pacientes sobre el conjunto original de entrenamiento (n=257), distribuyéndolo de la siguiente manera:

- **Entrenamiento (80%)**: aproximadamente 205 pacientes para el ajuste de los pesos de la red 3D U-Net.
- **Validación (10%)**: aproximadamente 26 pacientes para la monitorización de la pérdida (*Soft Dice Loss*) y prevención de sobreentrenamiento durante el ciclo de fit.
- **Test (10%)**: aproximadamente 26 pacientes completamente independientes y aislados, dedicados en exclusiva a la evaluación del rendimiento final expuesto en los resultados.

Al tratar con imágenes médicas en 3D, hemos tenido que estandarizarlas ya que los 257 pacientes incluidos proceden de diferentes centros sanitarios y se realizaron las resonancias con distintas máquinas.

Posteriormente para poder procesar las imágenes con el modelo que hemos implementado mediante keras (tensor flow) hemos tenido que dividir cada imagen en parches 3D, es decir unos cubos tridimensionales para no saturar la memoria RAM de nuestra computadora.

Finalmente el modelo clasifica cada vóxel presente en cada parche de forma consecutiva. La red neuronal analiza las características tridimensionales de cada vóxel y **calcula una probabilidad** para cada clase de tejido (cerebro sano, edema, tumor activo, quiste o necrosis de tejido). De esta manera, al integrar las predicciones de todos los parches se construye el cerebro completo del paciente y se genera un mapa de segmentación tridimensional.

Como lo acabamos de comentar, el modelo calcula la probabilidad de que cada vóxel de la imagen pertenezca a una clase, sin embargo en una resonancia cerebral la mayoría del tejido es sano y el tumor apenas representa 5% del total. Por lo tanto, existe un notable desbalance de clases y por ello el uso de una función de Entropía Cruzada Binaria no sería adecuado. Para evaluar la eficiencia de nuestro modelo y ajustarlo durante la fase de entrenamiento usaremos una función de pérdida basada en el **Soft Dice Coefficient**.

El Dice Coefficient se usa comúnmente en modelos de segmentación de imagen ya que mide el nivel de solapamiento entre dos contornos, en este caso entre el contorno delimitado por el experto en comparación con la delimitación realizada por nuestro modelo. El índice de Dice varía desde 0 (desajuste completo) hasta 1 (coincidencia perfecta). El Dice trabaja con valores discretos (0/1) cuando nuestro modelo regresa probabilidades, es la razón por la cual para la función de pérdida trabajamos con el **Soft Dice** ya que recibe números decimales continuos entre 0 y 1.

Adicionalmente, el Dice Coefficient se establece como la métrica principal para evaluar el desempeño final del modelo. Mientras que el *Soft Dice* actúa durante el entrenamiento para guiar la optimización de los pesos (función de pérdida), el *Dice Coefficient* discreto se utiliza en la fase de inferencia para cuantificar la precisión del modelo sobre los datos de validación. Esta métrica permite reportar un valor interpretable que refleja el grado de solapamiento real entre la segmentación predicha por el modelo y la verdad fundamental (*ground truth*) proporcionada por los expertos, permitiendo así realizar un seguimiento objetivo y comparable del progreso del modelo a lo largo de las distintas épocas. Si bien es una métrica de superposición no especifica la dirección del error, es decir si el modelo predice un tumor más pequeño o más grande de lo que es.

Debido a la naturaleza de los datos utilizados (volúmenes 3D de alta resolución), el entrenamiento del modelo alcanzó rápidamente el límite de capacidad de procesamiento de la infraestructura local. La segmentación volumétrica implica manejar tensores de gran tamaño que requieren una carga masiva de cálculos matriciales simultáneos. Para superarlo se migró el entorno de desarrollo de Jupyter Notebooks locales al de **Google Colab**

Resultados:

Primer entrenamiento :

Durante el primer entrenamiento llegamos a completar 11 épocas, es decir iteraciones completas donde el modelo ha visto **todo el conjunto de datos de entrenamiento exactamente una vez**. Se saturó la GPU de la versión gratuita de Google Collab y al revisar los resultados vimos que el modelo se había quedado estancado con un *Dice Coefficient* de 0.087 y la función de pérdida (*Soft Dice*) en 0.8652. En otras palabras, el modelo ya no estaba aprendiendo.

Por lo tanto procedimos a varios cambios, compramos créditos de GPU en Google Collab para poder realizar entrenamientos completos. Modificamos la función de pérdida y le incorporamos un **término de suavizado (*smoothing term*)** de 1.0 para asegurar la estabilidad del gradiente durante el entrenamiento.

Segundo entrenamiento:

Después de completar un entrenamiento completo de 30 épocas, obtuvimos un *Dice Coefficient* de 0.42, lo cual parecía una métrica aceptable. Sin embargo, al trabajar con un modelo multiclase, hemos procedido a desglosar esa métrica por cada clase. El análisis detallado por clase reveló un sesgo crítico de segmentación. El modelo presentaba una alta precisión en la identificación de la estructura general del tumor, pero un rendimiento dispar al clasificar el tejido. En efecto, el *Dice* de 0.42 estaba fuertemente influenciado por la clase NET (Non-Enhancing Tumor), mientras que las clases minoritarias, específicamente CC (Componente Quístico) y ED (Edema Peritumoral), presentaban un Dice cercano a 0.00.

El modelo no estaba realizando una segmentación multiclase real, sino que estaba "sobreajustado" a la morfología predominante en el dataset de entrenamiento, fallando en la distinción de tejidos con intensidades de señal similares.

En efecto, al extraer parches al azar de un volumen, el 90% de ellos será "fondo" (la etiqueta 0). El modelo, buscando minimizar su error, aprende rápidamente que la mejor estrategia es decir que todo es fondo. Incluso si encuentra algo, se sesga hacia la clase que más aparece (en nuestro caso, el NET).

Para solventar el desequilibrio de clases, se implementó una reestructuración del generador de datos (*get_sub_volume*) sustituyendo la búsqueda aleatoria de parches por una lógica de detección de etiquetas presentes en cada volumen. Hemos determinado que en el 70% de los casos el generador recibe un parche donde se sepa que hay tejido tumoral y el 30% restante sigue siendo aleatorio. De esta manera el modelo se ha expuesto con mayor frecuencia a las diferentes clases de tumor eliminando el sesgo hacia las clases mayoritarias.

Tercer entrenamiento:

Tras los reajustes de la muestra de imágenes, hemos podido completar el tercer y último entrenamiento. Los resultados de la fase de evaluación han sido los siguientes:

Clase	ET (Enhancing Tumor)	NET (Non-Enhancing)	CC (Cystic Component)	ED (Peritumoral Edema)
Dice Coefficient	0.425	0.695	0.369	0.371

Esos resultados demuestran una alta capacidad de segmentar tejido NET (tumor no realzante), sin embargo nos dimos cuenta que al volver a ejecutar el código estos resultados cambiaban y la razón era porque se usaba la misma configuración de extracción de sub volumen que para entrenar al modelo.

Para la fase de entrenamiento necesitamos exponer el modelo a tejido tumoral en mayor proporción para que aprenda a reconocerlo y delimitarlo sin embargo para la fase de validación el modelo tiene que enfrentarse a un parche fiel a la realidad es decir una mayoría de tejido sano y una proporción pequeña de tumor. Por lo tanto hemos vuelto a configurar la función de generación de sub volumen para que durante las fases de validación y evaluación presente parches centrados en la resonancia de cada paciente al modelo. Para el modo entrenamiento se activa la estrategia de 70% centrado en tumor y 30% aleatorio mencionada anteriormente.

De esta manera hemos obtenido los siguientes resultados:

Clase	ET (Enhancing Tumor)	NET (Non-Enhancing)	CC (Cystic Component)	ED (Peritumoral Edema)
Dice Coefficient	0.2730231	0.4681156	0.21718705	0.4967829

Evaluación del modelo:

Para la evaluación final del modelo, establecimos un umbral de decisión de **0.5** sobre las probabilidades generadas por la función Sigmoide. Este valor actúa como una frontera neutral y objetiva: cualquier probabilidad superior al 50% se interpreta como una detección positiva. Inicialmente, exploramos la modificación de este umbral de forma individualizada para cada clase con el objetivo de optimizar la sensibilidad; sin embargo, tras observar que las variaciones en las métricas de los resultados eran mínimas, decidimos mantener el umbral estándar de 0.5. Esta decisión garantiza un criterio de clasificación consistente, imparcial y robusto.

Los resultados obtenidos son los siguientes:

Clase	Dice Score	Sensibilidad	Especificidad
ET	0.5167	0.1209	0.9952
NET	0.3964	0.2213	0.9907
CC	0.4553	0.0361	0.9955

ED	0.3129	0.1162	0.9807
-----------	--------	--------	--------

Para el conjunto de clases notamos una **especificidad muy alta**, es decir que el modelo es excelente para "descartar" correctamente lo que no es la clase (es decir que hay muy **pocos falsos positivos**).

La **sensibilidad** presenta más heterogeneidad pero se mantiene **baja** en todas las clases lo cual sugiere que el modelo es conservador, prefiere marcar un píxel como cerebro sano antes que etiquetarlo falsamente como tumor (hay **muchos falsos negativos**).

Los Dice Coefficient oscilan entre 0.31 y 0.51 lo cual indica que el modelo encuentra la zona correcta del tumor pero le cuesta delimitar los bordes exactos de la lesión.

A nivel clínico, eso se traduce por una gran capacidad de apoyar al trabajo de los neurocirujanos para confirmar las zonas de cerebro sano y por lo tanto evitar removerlo o perjudicarlo durante el tratamiento oncológico. Sin embargo, al tener dificultades para delimitar precisamente el tumor y diferenciar las subregiones del tumor y en mayor proporción la clase de componente quístico. Esto se puede explicar por la naturaleza de esa clase, a diferencia del tumor sólido (ET y NET) es una región líquida con bordes difusos y un aspecto similar a otras áreas sanas del cerebro.




Figura 2. Comparativa cualitativa de la **segmentación binaria** de una lesión cerebral mediante U-Net 3D. Se muestra la resonancia original (T1), la máscara de segmentación de referencia (*Ground Truth*) y la predicción generada por el modelo para BraTS-PED-00030-000




Figura 3. Comparativa cualitativa de la **segmentación multiclase** de una lesión cerebral mediante U-Net 3D. Se muestra la resonancia original (T1), la máscara de segmentación de referencia (Ground Truth) y la predicción generada por el modelo para BraTS-PED-00030-000

- **ET (Enhancing Tumor):** Tumor con realce (captación de contraste).
- **NET (Non-Enhancing):** Tumor sin realce (tejido anormal).
- **CC (Cystic Component):** Componente quístico (relleno de líquido)
- **ED (Peritumoral Edema):** Edema peritumoral (inflamación circundante).

Discusión

Para la fase de entrenamiento, implementamos el modelo desde cero utilizando **Keras** con el fin de controlar minuciosamente el proceso de aprendizaje de la **U-Net 3D**. Durante esta etapa, utilizamos una estrategia de muestreo inteligente: los parches se centran específicamente en las regiones con presencia tumoral (muestreo enfocado), lo que permite al modelo priorizar la extracción de características patológicas y optimizar el uso de recursos computacionales. Por el contrario, para la fase de validación y evaluación, configuramos el modelo en un modo determinista que extrae siempre un parche fijo en el centro geométrico del volumen cerebral; esto elimina cualquier sesgo aleatorio y garantiza que las métricas de rendimiento sean consistentes y comparables entre épocas. Somos conscientes de que, en entornos clínicos profesionales, el estándar de oro (*gold standard*) es la **inferencia por ventana deslizante** (*sliding window*) automatizada mediante librerías como **MONAI**. Nuestra elección de trabajar manualmente ha sido motivada por la necesidad de formarnos una comprensión profunda de los cimientos del procesamiento de imágenes médicas.

El límite de tiempo y recursos nos impidió modificar el modelo para poder seguir entrenándolo. En un futuro se podría ajustar la función de pérdida con un balanceo de clases, es decir atribuir un peso mucho más elevado a las clases para las cuales el modelo es cauteloso (ED y CC) y presenta una sensibilidad más baja. Esta ponderación dirigida permitirá penalizar con mayor severidad los falsos negativos en esas regiones y fomentar el aprendizaje de sus estructuras de forma detallada.

De igual manera se implementaría un umbral adaptado a cada clase. En lugar de aplicar un umbral global de 0.5, el objetivo es ajustar individualmente el punto de corte para cada sub-región: reduciendo el umbral para las clases donde el modelo es excesivamente conservador (CC y ED), facilitamos la detección de estas estructuras al requerir un nivel de confianza

probabilística menor. Esta personalización del criterio de decisión permitirá compensar la falta de ejemplos en el entrenamiento, elevando la sensibilidad sin comprometer la especificidad global del sistema, y logrando así una segmentación más equilibrada para todas las estructuras patológicas.

Conclusión

Hemos logrado aplicar un modelo 3D UNET dirigido a un reto de segmentación de imágenes médicas. Si bien aún no podría usarse como apoyo a la toma de decisiones anteriormente al tratamiento de tumores cerebrales en niños, es capaz de ubicar el tumor y tiene un gran potencial de mejoría en caso de implementar los cambios mencionados anteriormente.

Referencias

Artículos de revista

Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016). 3D U-Net: Learning dense volumetric segmentation from sparse annotation. En S. Ourselin, L. Joskowicz, M. R. Sabuncu, G. Unal, & W. Wells (Eds.), *Medical image computing and computer-assisted intervention – MICCAI 2016* (Vol. 9901, pp. 424–432). Springer. https://doi.org/10.1007/978-3-319-46723-8_49

D’Orazio, J. A. (2010). Inherited cancer syndromes in children and young adults. *Journal of Pediatric Hematology/Oncology*, 32(3), 195–228. <https://doi.org/10.1097/MPH.0b013e3181d3f3f5>

Sudre, C. H., Li, W., Vercauteren, T., Ourselin, S., & Jorge Cardoso, M. (2017). Generalised Dice overlap as a deep learning loss function for highly unbalanced segmentations. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, 240–248. https://doi.org/10.1007/978-3-319-67558-9_28

Informes y páginas web

Asociación Española de Pediatría. (s.f.). *Cáncer infantil*. https://static.aeped.es/16_6ece0a1db8.pdf

Cancer Infantil. (s.f.). *Niños con cáncer*. <https://cancerinfantil.org/ninos-con-cancer/>

Organización Mundial de la Salud. (2026, 21 de junio). *Cáncer infantil*. <https://www.who.int/es/news-room/fact-sheets/detail/cancer-in-children>

Conjuntos de datos (Data sets)

Fathi Kazerooni, A., Khalili, N., Liu, X., Jiang, Z., Gandhi, D., Pavaine, J., Shah, L. M., Jones, B. V., Sheth, N., Prabhu, S. P., McAllister, A. S., Tu, W., Nandolia, K. K., Rodriguez, A., Shaikh, I. S., Sanchez-Montano, M., Lai, H. A., Haldar, D., Anderson, H., Bagheri, S., Zapaishchykova, A., Familiar, A. M., Gottipati, A., Haldar, S., Khalili, N., Maleki, N., Poussaint, T., Storm, P. B., Bornhorst, M., Packer, R., Hummel, T., de Blank, P., Hoffman, L., Aboian, M., Nabavizadeh, A., Ware, J. B., Kann, B. H., Bakas, S.,

Rood, B., Resnick, A., Vossough, A., & Linguraru, M. G. (2025). *The Brain Tumor Segmentation in Pediatric Magnetic Resonance Imaging (BraTS-PEDs)* (Version 1) [Data set]. The Cancer Imaging Archive. <https://doi.org/10.7937/DX5C-TJ86>