

Segmentación automatizada de tumores cerebrales en niños

Implementación de un modelo 3D Unet

Introducción: Contexto Clínico

- Cáncer: la primera causa de mortalidad en menores en España
- La supervivencia depende del acceso al diagnóstico y a los tratamientos
- Tumores cerebrales: es necesario evaluar y segmentar el tumor antes de tratarlo : una carga de trabajo enorme para los cirujanos (volumen 3D de 155 capas)

Introducción: el reto de la especificidad pediátrica

- Muchos métodos de segmentación de tumores cerebrales en adultos, pocos en niños
- Anatomía más compleja:
 - presencia de quistes alrededor del tumor (líquido atrapado)
 - límites difusos

➡ Ineficiencia de los modelos de segmentación desarrollados para adultos

Problema:

- Necesidad clínica de segmentar un tumor antes de operar / tratar
- Falta de recursos: humanos y materiales
- Carrera Contra-reloj



necesidad de agilizar ese proceso previo

Dataset : BraTS - PEDs 2025

- The Brain Tumor Segmentation in Pediatric Magnetic Resonance Imaging
- Base de datos con 457 registros (pacientes con tumor)
 - **257** registros con **etiquetas** validadas (máscaras) por expertos (**Ground Truth**)
- División de esos 257 :


Entrenamiento : 205	Validación : 26	Prueba : 26
----------------------------	------------------------	--------------------

Dataset : BraTS - PEDs 2025

Para cada registro :

- **Resonancia Magnética Multiparamétrica :**
 - 4 archivos (240, 240, 155)
 - T1 : básica
 - T1c : con contraste
 - T2: sensible a los líquidos
 - T2 Flair: apaga el líquido cefalorraquídeo, resalta el edema peritumoral

Dataset : BraTS - PEDs 2025




(<https://www.sciencedirect.com/science/article/pii/S2772528624000013>)

Dataset : BraTS - PEDs 2025

- **Resonancia con máscara de segmentación del tumor: 5 clases**
 - 0: Normal
 - 1: Tumor con realce (ET)
 - 2: Tumor sin realce (NET)
 - 3: Componente quístico (CC)
 - 4: Edema peritumoral (ED)

Dataset : BraTS - PEDs 2025



(<https://www.sciencedirect.com/science/article/pii/S2772528624000013>)


Metodología: Modelo 3D-Unet

- Red Neuronal Convolutional

- Segmentación semántica

→ clasifica cada vóxel en una categoría de tejido

4 Volumetric Segmentation with the 3D U-Net




Tomado de "3D U-Net: Learning dense volumetric segmentation from sparse annotation", de Ö. Çiçek et al., 2016,

Metodología: Modelo 3D-Unet

- Ruta de contracción (**Encoder**)
- Ruta de expansión (**Decoder**)
- **Skip Connections** (puentes)

4 Volumetric Segmentation with the 3D U-Net



Tomado de "3D U-Net: Learning dense volumetric segmentation from sparse annotation", de Ö. Çiçek et al., 2016,

Flujo del proceso de Entrenamiento

INPUT

Parches 3D: normalizados
(160, 160, 16)

Canales: 4

Muestreo Híbrido:
70% tumor / 30% aleatorio

PROCESAMIENTO

Arquitectura : 3D-Unet

Estructura: Encoder,
Decoder, Conexiones

Función pérdida: Soft Dice

OUTPUT

Predicción: Mapa de
probabilidades

- Tejido normal
- Tumor realzante
- Tumor no realzante
- Quiste
- Edema

Función de pérdida : Soft Dice Loss

- Sirve para guiar el aprendizaje del modelo (Loss Function)
- Calcula la discrepancia entre la distribución de probabilidades del modelo y el Ground Truth
- Ajusta el modelo en cada época (ciclo de entrenamiento)

Evaluación : Dice Coefficient

- Para medir la precisión del modelo en fase de validación y prueba
- Gold standard en segmentación médica
- Binarización: los mapas de probabilidad se convierten en máscaras binarias (0/1) usando un **umbral de 0.5**
- Se determina el **índice de solapamiento** entre la máscara predicha por el modelo y la máscara de los expertos:

0 : desajuste completo

1: coincidencia perfecta

Resultados :

- Jupyter Notebook en Google Collab
- **Cambio de muestreo** : se presentan parches en el centro geométrico (no centrado en tumor ni aleatorio)
- Evaluación del modelo entrenado con **30 épocas**

Resultados : Métricas

Clase	Dice Score	Sensibilidad	Especificidad
ET (realce)	0.5167	0.1209	0.9952
NET (sin realce)	0.3964	0.2213	0.9907
CC (Quiste)	0.4553	0.0361	0.9955
ED (Edema)	0.3129	0.1162	0.9807

Resultados : Métricas

Clase	Dice Score	Sensibilidad	Especificidad
ET (realce)	0.5167	0.1209	0.9952
NET (sin realce)	0.3964	0.2213	0.9907
CC (Quiste)	0.4553	0.0361	0.9955
ED (Edema)	0.3129	0.1162	0.9807

- **Alta especificidad** constante (>99%): el modelo prioriza la seguridad clínica minimizando falsos positivos.
- **Dice Score (0.31-0.51)**: el modelo indica la zona correcta del tumor pero presenta variabilidad para delimitar sus bordes.

Resultados : Visualización de un caso




Figura 2. Comparativa de la **Segmentación Binaria** (Todo el tumor vs. Fondo) de un tumor cerebral mediante U-Net 3D (BraTS-PED-00030-000)

Resultados : Visualización de un caso




Figura 3. Comparativa de la **segmentación multiclase** de un tumor cerebral mediante U-Net 3D (BraTS-PED-00030-000)

- **ET (Enhancing Tumor):** Tumor con realce (captación de contraste).
- **NET (Non-Enhancing):** Tumor sin realce (tejido anormal).
- **CC (Cystic Component):** Componente quístico (relleno de líquido)
- **ED (Peritumoral Edema):** Edema peritumoral (inflamación circundante).

Conclusión

- Seguridad Vs Agresividad del modelo : se evitan falsos positivos
- **Pistas de optimización:**
 - Ajuste de la Función de Pérdida : atribuir más peso a las clases minoritarias
 - Existencia de herramientas automatizadas : Monai, nnU-NET